

Programowo-Sprzętowa Realizacja Algorytmów:
wyznaczanie i śledzenie punktów
charakterystycznych

Wojciech Gumuła, Rafał Prusak

3 kwietnia 2016

Spis treści

1	Metody wykrywania punktów charakterystycznych.	2
1.1	Metoda Harrisa	3
1.1.1	Implementacja w OpenCV	4
1.2	Metoda Susan	5
1.3	Metoda Fast	6
1.3.1	Implementacja w OpenCV.	7
2	Analiza istniejących rozwiązań	9
2.1	Dopasowywanie punktów w obrazie przestrzennym oparte na wykrywaniu narożników.	9
2.2	Odporny algorytm dopasowywania szablonów za pomocą wykrywania narożników dla systemów wizyjnych robotów.	10
3	Opis systemu detekcji i śledzenia.	13
4	Implementacja C++.	14
5	Podział HW/SW.	15
6	Uruchomienie na Zybo.	16

Rozdział 1

Metody wykrywania punktów charakterystycznych.

Ważnym zagadnieniem w systemach wizyjnych jest pozyskiwanie informacji z obrazu, a następnie podejmowanie dalszych działań na podstawie pozyskanych danych.

Wyznaczanie punktów charakterystycznych ma na celu wybór „interesujących” elementów bądź rejonów obrazu oraz uzyskanie charakterystyki specyficznej dla danej aplikacji. Jest to często niskopoziomowa składowa bardziej złożonych algorytmów. Uzyskanie punktów charakterystycznych pozwala na rozpoznawanie kształtów, wyszukiwanie elementów pasujących do wzorca czy też śledzenie obiektów w obrazie wideo.

Istnieje kilka rodzajów punktów uznawanych jako charakterystycznych:

- krawędzie,
- narożniki,
- krople(ang „blobs”).

Szczególnym „powodzeniem” ciszą się narożniki. Punkt te powstają w miejscu krzyżowania się lub gwałtownej zmiany kształtu krawędzi. Z tego powodu, w punkcie narożnym dochodzi do nagłej zmiany wartości gradientu obrazu, co znacząco ułatwia poszukiwanie tego punktu.

1.1 Metoda Harrisa

Algorytm Harrisa polega na analizie jasności obrazu i wyszukiwaniu zmian gradientu.

Poszukiwane są odchylenia jasności:

$$E(u, v) = \sum_{x,y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$

gdzie:

- $w(x, y)$ - okno w punkcie (x, y) o wymiarach $u \times v$,
- $I(x, y)$ - jasność w punkcie (x, y) ,
- $I(x + u, y + v)$ - jasność w drugim punkcie okna.

Poszukujemy znaczącego odchylenia, więc celem jest maksymalizacja:

$$\sum_{x,y} [I(x + u, y + v) - I(x, y)]^2$$

Po rozwinięciu w szereg Taylora:

$$E(u, v) \approx \sum_{x,y} [I(x, y) + uI_x + vI_y - I(x, y)]^2$$

Dokonujemy skrócenia:

$$E(u, v) \approx \sum_{x,y} u^2 I_x^2 + 2uv I_x I_y + v^2 I_y^2$$

Równanie można zapisać w postaci macierzowej:

$$E(u, v) \approx [u \ v] M \begin{bmatrix} u \\ v \end{bmatrix}$$

z macierzą w postaci:

$$M = \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

Dla każdego okna wyliczana jest wartość wyrażenia:

$$R = \det(M) - k(\text{trace}(M))^2$$

gdzie:

- $\det(M) = \lambda_1 \lambda_2$
- $\text{trace}(M) = \lambda_1 + \lambda_2$

Wartość wyrażenia R powyżej pewnej wartości granicznej oznacza występowanie narożnika.

1.1.1 Implementacja w OpenCV

Poniższy kod prezentuje wykrywanie narożników za pomocą biblioteki OpenCV:

```

1  #include "opencv2/highgui.hpp"
2  #include "opencv2/imgproc.hpp"
3  #include <iostream>
4  #include <stdio.h>
5  #include <stdlib.h>
6
7  using namespace cv;
8  using namespace std;
9
10 Mat src, src_gray;
11 int thresh = 200;
12 int max_thresh = 255;
13
14 char* source_window = "Source_image";
15 char* corners_window = "Corners_detected";
16
17 void cornerHarris_demo( int, void* ) {
18     Mat dst, dst_norm, dst_norm_scaled;
19     dst = Mat::zeros(src.size(), CV_32FC1);
20
21     int blockSize = 2;
22     int apertureSize = 3;
23     double k = 0.04;
24
25     cornerHarris(src_gray, dst, blockSize, apertureSize, k, BORDER_DEFAULT);
26
27     normalize(dst, dst_norm, 0, 255, NORM_MINMAX, CV_32FC1, Mat());
28     convertScaleAbs(dst_norm, dst_norm_scaled);
29
30     for (int j=0; j<dst_norm.rows; j++) {
31         for (int i=0; i<dst_norm.cols; i++) {
32             if((int)dst_norm.at<float>(j,i) > thresh)
33                 circle(dst_norm_scaled, Point(i, j), 5, Scalar(0), 2, 8, 0);
34         }
35     }
36
37     namedWindow(corners_window, WINDOW_AUTOSIZE);
38     imshow(corners_window, dst_norm_scaled);
39 }
40
41 int main( int argc, char** argv ) {
42     src = imread(argv[1], 1);
43     cvtColor(src, src_gray, COLOR_BGR2GRAY);
44
45     namedWindow(source_window, WINDOW_AUTOSIZE);
46     createTrackbar("Threshold:", source_window, &thresh, max_thresh, cornerHarris_demo);
47     imshow(source_window, src);
48     cornerHarris_demo(0, 0);
49     waitKey(0);
50     return(0);
51 }

```



Rysunek 1.1: Wykrywanie narożników metodą Harisa w OpenCV

1.2 Metoda Susan

Algorytm SUSAN (ang. Smallest Univalve Segment Assimilating Nucleus) polega na znajdowaniu pikseli, które w otoczeniu mają najniższą liczbę punktów o zbliżonej jasności.

$$c(r, r_0) = \begin{cases} 1 & \text{gdy } |I(r) - I(r_0)| \leq t \\ 0 & \text{gdy } |I(r) - I(r_0)| > t \end{cases}$$

gdzie:

- I - jasność obrazu,
- r_0 - piksel centralny,
- t - próg podobieństwa pikseli

Liczbę pikseli podobnych wyznaczamy następująco:

$$D(r_0) = \sum_{r \in N(r_0)} c(r, r_0)$$

gdzie $N(r_0)$ to otoczenie piksela centralnego.

Aby punkt był uznany za narożnik, co najwyżej połowa punktów jego otoczenia może być do niego podobna.

1.3 Metoda Fast


Algorytm Fast (ang. Features from Accelerated Segment Test) opiera się, podobnie jak Susan, na przeszukaniu otoczenia piksela.

Opis algorytmu:

1. Wybieramy piksel p o poziomie jasności I_p .
2. Wybieramy wartość progu t .
3. Wybieramy okrąg o promieniu $r = 16$ pikseli.
4. Piksel p jest narożnikiem jeżeli na okręgu znajduje się ciąg pikseli jaśniejszych niż $I_p + t$ lub ciemniejszych niż $I_p - t$.

Algorytm ten został udoskonalony przez dodanie testu, który pozwala bardzo szybko odrzucić dużą liczbę punktów nie będących narożnikami. W tym teście sprawdzana jest jasność po kolei pikseli 1, 9, 5, 13.

Dobór okręgu został przedstawiony na rysunku 1.2.



Rysunek 1.2: Wybór otoczenia piksela w metodzie FAST.

1.3.1 Implementacja w OpenCV.

Poniższy kod prezentuje wykrywanie narożników metodą Fast za pomocą biblioteki OpenCV:

```

1  #include <opencv2/highgui.hpp>
2  #include <opencv2/imgproc.hpp>
3  #include <opencv2/features2d.hpp>
4  #include <vector>
5  #include <iostream>
6
7  using namespace cv;
8  using namespace std;
9
10 Mat src, src_gray;
11 int thresh = 20;
12 int max_thresh = 50;
13
14 char* source_window = "Source_image";
15 char* corners_window = "Corners_detected";
16
17 void Fast_demo(int, void *) {
18     std::vector<KeyPoint> points;
19     FAST(src_gray, points, thresh);
20
21     auto temp = src_gray.clone();
22
23     for(auto keyPoint: points) {
24         int x = keyPoint.pt.x;
25         int y = keyPoint.pt.y;
26         Point p{x, y};
27         circle(temp, p, 5, Scalar(0));
28     }
29
30     namedWindow(corners_window, WINDOW_AUTOSIZE);
31     imshow(corners_window, temp);
32 }
33
34 int main(int argc, char** argv) {
35     src = imread(argv[1], 1);
36     cvtColor(src, src_gray, COLOR_BGR2GRAY);
37     namedWindow(source_window, WINDOW_AUTOSIZE);
38     createTrackbar("Threshold: ", source_window, &thresh, max_thresh, Fast_demo);
39     imshow(source_window, src);
40     Fast_demo(0, 0);
41     waitKey(0);
42     return (0);
43 }

```




Rysunek 1.3: Wykrywanie punktów charakterystycznych metodą Fast ($t=50$).

Rozdział 2

Analiza istniejących rozwiązań

2.1 Dopasowywanie punktów w obrazie przestrzennym oparte na wykrywaniu narożników.

Na podstawie artykułu: „A New Stereo Matching Method Based on Sub-pixel Corner Detection”(Dou Zhao, Ding Liu, Yanxi Yang).

Znajdowanie i dopasowywanie punktów charakterystycznych odgrywa ważną rolę w przetwarzaniu obrazu 3D, wykrywaniu i śledzeniu obiektów. W tych zagadnieniach warunkiem koniecznym jest wysoka wydajność systemu oraz dokładność detekcji.

W zagadnieniach praktycznych wyróżnia się 3 podejścia: dopasowywanie obszarów(ang. „Area-based”), dopasowywanie punktów charakterystycznych oraz dopasowywanie fazowe(ang. „Phase-based”). Pierwsza metoda zapewnia wysoką precyzję, ale posiada znaczące wady w postaci trudności wyliczania rozmiaru okna oraz znacznego nakładu obliczeń. Kolejna metoda wyróżnia się odpornością na zakłócenia i wysoką wydajnością. Niestety, cechuje się ona również zmniejszoną precyzją. Ostatnia metoda jest w stanie usuwać szumy wysokiej częstotliwości oraz jest łatwa do implementacji za pomocą obliczeń równoległych.


W celu poprawy dopasowywania metody punktów charakterystycznych, została opracowana podwójna metoda Harisa z dopasowywaniem punktów opartym na poziomie jasności. Algorytm ten składa się z następujących kroków:

1. Konwersja obrazu na skalę szarości i filtracja.
2. Wykrycie narożników standardową metodą Harisa.
3. Obraz jest dzielony na mniejsze bloki rozmiaru $n \times n$ zawierające wykryte krawędzie.

4. Dokonywana jest interpolacja jasności każdego z regionów.

Dopasowywanie punktów odbywa się za pomocą wyliczania charakterystyki R każdego punktu i analizie stosunku wartości charakterystyk. Stosunek zbliżony do 1 oznacza dokładne dopasowanie.

Poniższy obraz prezentuje rezultat algorytmu:



Rysunek 2.1: Dopasowanie punktów charakterystycznych.

W zaprezentowanym przykładzie błąd wyniósł około 38%.

2.2 Odporny algorytm dopasowywania szablonów za pomocą wykrywania narożników dla systemów wizyjnych robotów.

Na podstawie artykułu „Robust Template Based Corner Detection Algorithms for Robotic Vision”.

Wykrywanie narożników z powodu wydajności i niskiej złożoności obliczeniowej znalazło szereg zastosowań w systemach wizyjnych robotów. W połączeniu z odpowiednim zaprojektowaniem szablonów poszukiwanych elementów można uzyskać bardzo efektywne aplikacje. W artykule zarezentowano dwa podejścia do tematu: detekcja na podstawie dopasowywania narożników (MBCD - ang. „matching based corner detection”) oraz dopasowywanie na podstawie korelacji punktów (CBCD - ang. „correlation based corner detection”).

Z powodu ograniczonych zasobów sprzętowych w systemach wizyjnych robotów kluczowym elementem jest dobór algorytmu i poszukiwanych obiektów. Systemy te muszą działać na podobnej zasadzie co układ wzrokowy człowieka: być szczególnie czułym na elementy o wysokiej częstotliwości, takie jak krawędzie oraz narożniki.

Istniejące metody wykrywania punktów charakterystycznych można podzielić na dwie grupy: oparte na obliczaniu gradientów lub poszukiwaniu podobieństw. Pierwsza grupa algorytmów jest czuła na zakłócenia. Druga grupa algorytmów opiera się na poszukiwaniu podobieństw pomiędzy pikselami.

W wykorzystaniu szablonów zasadnicze znaczenie mają dwie kwestie: jakiego typu użyć szablon oraz jak zmierzyć różnice. Przykładowe szablony do

wykrywania rogów prezentuje poniższy obraz:

-9	-9	-9	-9	-9
-9	-9	-9	-9	-9
-9	-9	16	16	16
-9	-9	16	16	16
-9	-9	16	16	16


-4	-4	-4
-4	5	5
-4	5	5

1	1
1	0

Rysunek 2.2: Szablony do wykrywania narożników.

Pomiar różnic pomiędzy szablonami dokonywany jest za pomocą 3 metod: korelacji znormalizowanej, normy ko-sinusowej oraz pomiarze odwzorowania.

Wykorzystanie szablonów opiera się na założeniu, że w obrazie istnieją idealne narożniki.



Rysunek 2.3: Przykłady narożniki.

Metoda MBCD polega na wykorzystaniu trzech poniższych szablonów:

1	0
0	1
1	0

1	0
1	0
1	1

0	1
0	1
1	1

Rysunek 2.4: Szablony metody MBCD.

Następnie, każdy z tych szablonów jest obracany o 90 stopni w wyniku czego otrzymujemy 12 szablonów. Punkt jest uznawany za narożnik jeśli pasuje do co najmniej dwóch z pośród wszystkich szablonów.

Metoda CBCD posługuje się 3 szablonami:

1	0	1
0	1	0
1	0	1

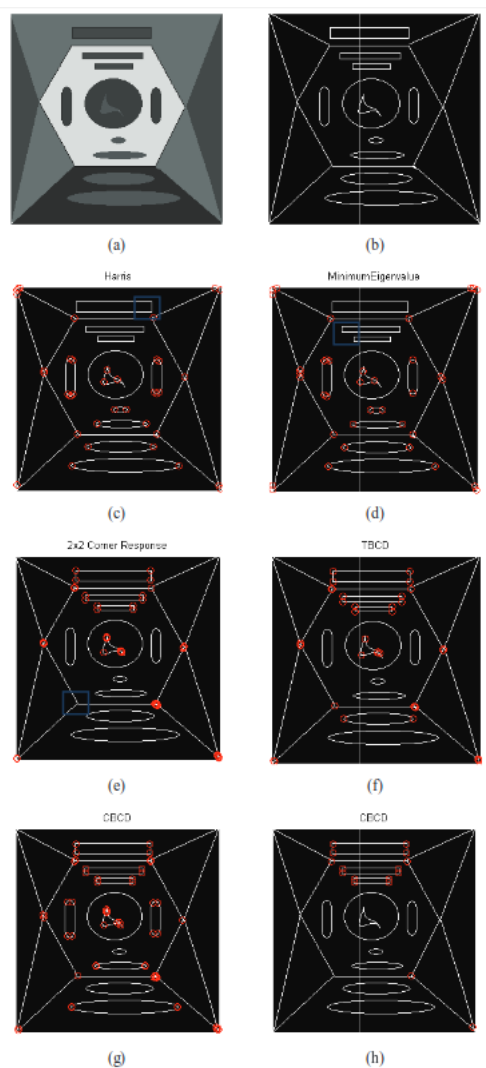
1	0	0
1	0	0
1	1	1

0	0	1
0	0	1
1	1	1

Rysunek 2.5: Szablony metody CBCD.

Są one obracane o 90 stopni, w wyniku czego otrzymuje się 9 szablonów. Pikiel jest testowany pod względem podobieństwa z każdym z tych szablonów.

Poniższy obraz prezentuje porównanie algorytmów wykrywania rogów w systemach wizyjnych robotów:



Rysunek 2.6: Porównanie algorytmów.

Rozdział 3

Opis systemu detekcji i śledzenia.

Rozdział 4

Implementacja C++.

Rozdział 5

Podział HW/SW.

Rozdział 6

Uruchomienie na Zybo.